統計與機器學習 期末專題報告

流行病學與預防醫學研究所 R13849007 李宗榮

一、 研究背景與動機

心血管疾病每年在全球造成約 1700 萬人死亡。近年來，心臟衰竭的盛行率呈現上升趨勢。心臟衰竭是指心臟無法將足夠的血液泵送到身體各部位，通常由糖尿病、高血壓及其他心臟疾病所引起。在臨床診斷上，心臟衰竭可以依照射血分率（Ejection Fraction, EF）的數值分為兩類，分別是左心室低收縮分率心臟衰竭（HFrEF）和左心室正常收縮分率心臟衰竭（HFpEF）。HFrEF 的特徵是射血分率低於 40%，而 HFpEF 為左心室在收縮期正常收縮，但心室僵硬，所以在舒張期無法正常放鬆。另外，醫生經常根據紐約心臟協會（NYHA）的分類標準，將心臟衰竭的病程分為四個等級，從日常活動無症狀（I 級）到任何體力活動皆會引起不適（IV 級）。然而，即便結合血液中的生物標記和 NYHA 的分級制度仍無法準確評估心臟衰竭患者的長期預後結果。因此，本報告旨在利用臨床數據建立具可解釋性的預測模型，輔助醫療決策者及早辨識預後較差的高風險人群，以改善心臟衰竭患者的治療決策與照護品質。

二、 資料來源與前處理

1. 資料來源與描述

本報告使用的資料來源至巴基斯坦旁遮普省費的心臟病研究所與附屬醫院（https://archive.ics.uci.edu/dataset/519/heart+failure+clinical+records），資料收集 2015 年 4 月至 12 月心臟衰竭患者的醫療診斷紀錄。資料中的患者皆被診斷為 HFpEF，且符合 NYHA 心臟衰竭分級標準的 III 級或 IV 級。資料包含 13 個欄位，涵蓋人口特徵、臨床數據及生活習慣等資訊（如表 1 所示）。

肌酸激酶（CPK）為血液中 CPK 的濃度，當肌肉組織受損時，CPK 會流入血液。因此，較高的 CPK 濃度可能代表心臟處於衰竭或損傷的狀態。射血分率為左心室每次收縮時泵血的百分比。血清肌酸酐是肌肉分解所產生的代謝物，醫生通常會利用血液中的肌酸酐濃度評估患者的腎臟功能。若血清肌酸酐較高則代表患者可能存在腎功能障礙。血清鈉是參與肌肉收縮和神經傳導的重要礦物質，研究指出血液中鈉含量較低可能是由心臟衰竭所引起。最後，死亡事件為本報告的目標變數，代表患者在追蹤期間是否發生死亡。

表1. 變數型態與描述。

變項名稱	說明	單位	數值範圍
年齡 (Age)	患者年齡	年	[40, …, 95]
肌酸激酶 (CPK)	血液中CPK的濃度	mcg/L	[23, …, 7861]
射血分率 (EF)	每次心跳時，左心室泵血的程度	百分比	[14, …, 80]
血小板 (Platelets)	血液中血小板的數量	kiloplatelets/mL	[25.01, …, 850]
肌酸酐 (Creatinine)	血液中肌酸酐的濃度	mg/dL	[0.5, …, 9.4]
血清鈉 (Serum sodium)	血清中鈉離子濃度	mEq/L	[114, …, 148]
追蹤時間 (Time)	開始到結束追蹤的天數	天	[4, …, 285]
性別 (Sex)	患者性別	二元變數	0 = 女 / 1 = 男
吸菸 (Smoking)	患者是否吸菸		0 = 否 / 1 = 是
貧血 (Anaemia)	紅血球或血紅素不足		0 = 無 / 1 = 有
高血壓 (HBP)	患者是否有高血壓		
糖尿病 (Diabetes)	患者是否有糖尿病		
死亡事件 (Death event)	追蹤期間是否發生死亡		0 = 存活 / 1 = 死亡

2. 資料前處理

該筆資料不存在遺失值，因此沒有進行數值插補。雖然我們使用直方圖檢查連續型變數的數值分布時，發現 CPK 有明顯較高的離群值，但進一步檢查其數值超過 7000 mcg/L 的患者資料後發現，兩名患者皆在追蹤期間內發生死亡，尤其是 CPK 高達 7861 mcg/L 的患者在追蹤 6 天後就發生死亡。考量到該資料皆為心臟衰竭患者的臨床數據，不適用於一般人群的正常值範圍。因此，我們參考了使用該資料的相關研究，在兩篇已發表研究中皆沒有排除特定患者的資料，所以我們最終決定保留所有的原始資料進行後續分析。儘管如此，我們仍有定義 CPK 超過平均值正負三個標準差的範圍為異常值，進行敏感度分析。綜上所述，經過嚴謹的資料探索後，我們並沒有對該筆資料進行前處理。

三、 分析策略與模型建構

1. 資料探索

首先，我們使用直方圖確定連續型變數不服從常態分布，因此連續型變數以中位數和四分位距呈現，並使用 Mann-Whitney U test 比較其值在死亡組與存活組中是否有顯著差異。另外，我們使用 Spearman 等級相關係數檢定連續型變數之間的相關性。針對類別型變數，我們以頻率計數和百分比呈現，並使用 Chi-Squared Test 檢定該變數和存活與否的相關性。

2. 模型建構

基於我們的目的是要建立一個輔助醫療決策者識別高風險人群的預測模型，因此我們排除了「追蹤時間」這項變數。因為患者進入醫院後，我們無法預期患者未來被追蹤的時間，所以使用該變數預測存活風險並不合理。誠如上述，我們最終使用了年齡、性別、吸菸狀態、貧血病史、高血壓病史、糖尿病病史、射血分率以及四種血液中的生物標記建立預測模型。為了評估模型的表現，我們選擇使用五折交叉驗證分別建立 Logistic Regression、Decision Tree、Random Forest 及 XGBoost 等預測模型。針對 Tree-based 模型，我們使用網格搜尋法（Grid search）調整模型的超參數，其設定如下表所示：

表2. 網格搜尋法的參數設定。

Decision Tree	Random Forest	XGBoost
max_depth：2, 3, 5, 10 min_samples_leaf：5, 10, 20, 50	n_estimators：50, 100, 150, 200 max_depth：5, 10, 15, 20 min_samples_leaf：1, 5, 10, 20	n_estimators：50, 100, 150, 200 max_depth：3, 5, 7, 10 learning_rate：0.01, 0.05, 0.10, 0.20 subsample：0.8, 1.0

最後，我們重新擬合全部的資料，透過 Logistic Regression 估計各變數的平均勝算比，以幫助我們解釋各變數對存活狀態的影響。Tree-based 模型則是使用 Shapley value 檢查各變數的重要性。接著，我們排除重要性較低的變數，建立 Reduced Model，並比較 Full Model 和 Reduced Model 的模型表現。

3. 驗證存活風險

為了驗證我們建構的模型是否能有效區分預後較差的人群，我們將資料重新切分成 70% 訓練集和 30% 測試集，並使用最終模型的最佳參數進行配適。最後，以 0.5 作為切點，將最終模型的預測結果分為高風險人群和低風險人群，並使用 Kaplan-Meier 方法分析兩組的存活表現是否存在顯著差異。

4. 模型評估指標

在五折交叉驗證中，我們計算平均 ROC 曲線下面積，並使用每一折的混淆矩陣計算「準確度」、「召回率」、「特異度」、「陽性預測值」及「陰性預測值」的平均表現（如表 3 所示）。在本報告中，我們最關注的指標是「召回率」，因為我們希望能最大程度避免高風險族群被錯誤分類為低風險族群。

表3. 六項模型評估指標。

指標名稱	公式	意義
ROC曲線下面積 (AU-ROC)	_	_
準確度 (Accuracy)	(TP + TN) / (TP + TN + FP + FN)	預測正確佔整體的比例
召回率 (Recall)	TP / (TP + FN)	正確預測出真實陽性的比例
特異度 (Specificity)	TN / (TN + FP)	正確預測出真實陰性的比例
陽性預測值 (PPV)	TP / (TP + FP)	預測為陽性的正確率
陰性預測值 (NPV)	TN / (TN + FN)	預測為陰性的正確率

四、 分析結果

1. 探索性資料分析

本報告分析了 299 位心臟衰竭患者的臨床資料。其中，有 96 位患者在追蹤時間內發生死亡，而其餘 203 位患者在追蹤時間內沒有發生死亡。表 4 為連續型變數的統計檢定量。結果顯示，死亡組的年齡中位數為 65 歲，而存活組為 60 歲，經檢定後得 p 值小於 0.05，故兩組的年齡中位數有顯著差異，代表高齡為死亡風險的重要預測因子。另外，死亡組的射血分率中位數為 30%，亦低於存活組的 38%，其 p 值小於 0.05，表示射血分率與患者存活風險有關。在腎功能的指標方面，死亡組血清肌酸酐的中位數為 1.30 mg/dL，高於存活組 1.00 mg/dL，其 p 值小於 0.05，代表腎功能受損與預後較差有關。血清鈉濃度在死亡組中位數為 135.5 mEq/L，低於存活組 137 mEq/L，其 p 值小於 0.05，代表兩組患者的血清鈉濃度中位數有顯著差異。死亡組的追蹤時間中位數為 44.5 天，少於存活組 172 天，其 p 值小於 0.05，代表死亡組的追蹤時間顯著低於存活組。不過，兩組的 CPK 濃度與血小板數量則沒有顯著差異。總結來說，年齡、射血分率、肌酸酐、血清納及追蹤時間在存活組和死亡組中有顯著差異。

表 5 為類別型變數的統計檢定量。在性別方面，資料包含 194 位男性，佔 64.9%，而女性佔 35.1%。在吸菸狀態方面，共有 203 位患者沒有吸菸，佔整體 67.9%，代表該群患者的煙草暴露比例較低。在相關的病史方面，貧血、高血壓及糖尿病的比例分布相似，皆以沒有病史佔多數。經過卡方檢定後發現，五個類別型變數皆未達統計顯著，顯示資料的人群分布中，死亡組和存活組的性別、吸菸狀態及常見的共病症無顯著相關。

表4. 連續型變數的統計檢定量。

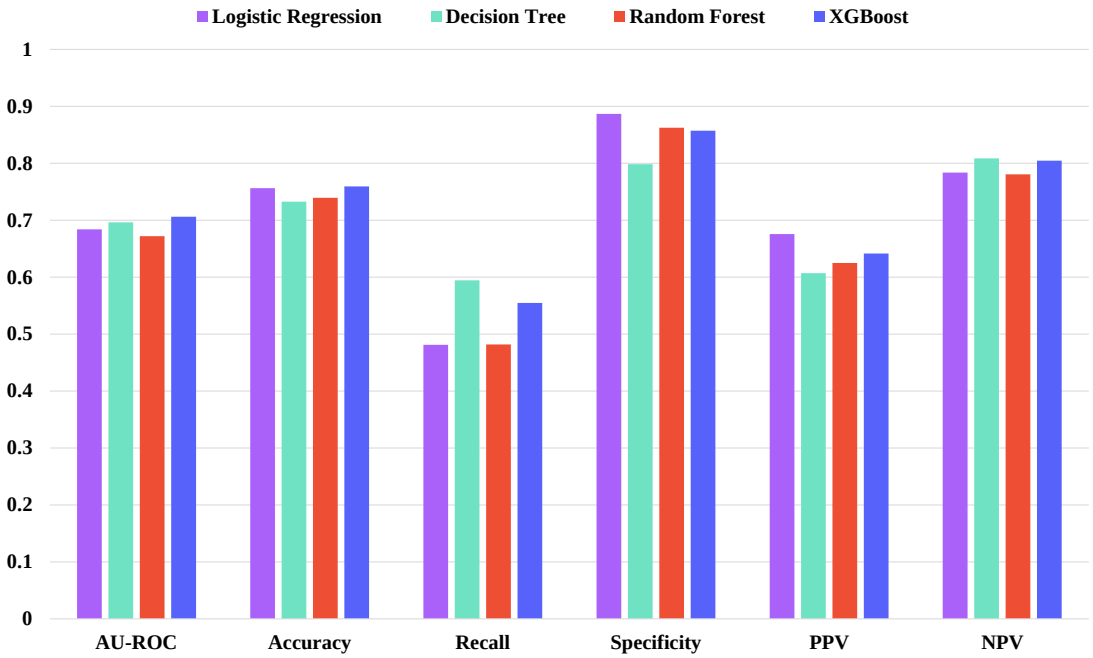
		Total (n=299)		Survived (n=203)		Dead (n=96)		
		Median	IQR	Median	IQR	Median	IQR	p-value
年齡 (Age)	years	60.00	19.00	60.00	15.00	65.00	20.00	<0.001
肌酸激酶 (CPK)	mcg/L	250.00	467.00	245.00	473.00	259.00	453.50	0.684
射血分率 (EF)	%	38.00	15.00	38.00	10.00	30.00	13.00	<0.001
血小板 (Platelets)	kiloplatelets/mL	262.00	92.00	263.00	83.00	258.50	115.00	0.426
肌酸酐 (Creatinine)	mg/dL	1.10	0.50	1.00	0.30	1.30	0.85	<0.001
血清鈉 (Serum sodium)	mEq/L	137.00	6.00	137.00	5.00	135.50	5.50	<0.001
追蹤時間 (Time)	days	115.00	132.00	172.00	118.00	44.50	79.50	<0.001

表5. 類別型變數的統計檢定量。

		Total (n=299)		Survived (n=203)		Dead (n=96)		
		n	%	n	%	n	%	p-value
性別 (Sex)	male	194	64.88	132	65.02	62	64.58	0.941
	female	105	35.12	71	34.98	34	35.42	
吸菸 (Smoking)	no	203	67.89	137	67.49	66	68.75	0.827
	yes	96	32.11	66	32.51	30	31.25	
貧血 (Anaemia)	no	170	56.86	120	59.11	50	52.08	0.252
	yes	129	43.14	83	40.89	46	47.92	
高血壓 (HBP)	no	194	64.88	137	67.49	57	59.38	0.170
	yes	105	35.12	66	32.51	39	40.62	
糖尿病 (Diabetes)	no	174	58.19	118	58.13	56	58.33	0.973
	yes	125	41.81	85	41.87	40	41.67	

2. 五折交叉驗證的平均模型表現

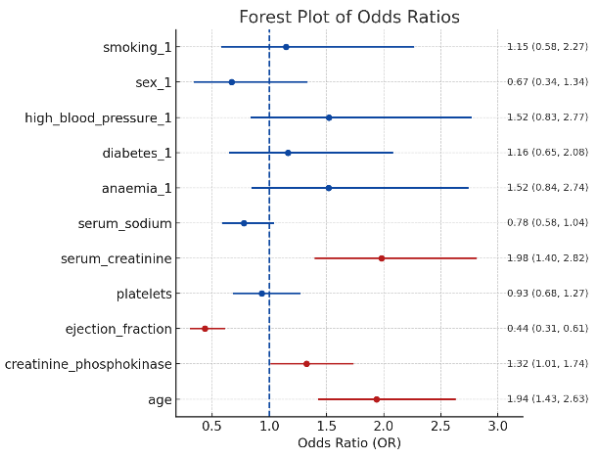
比較模型表現的結果顯示，XGBoost 在多數模型評估指標上表現較佳。具體而言，XGBoost 的 AU-ROC 最高達到 0.706，高於其他三種模型，同時其整體準確率以 0.759 略勝 Logistic Regression 的 0.756，而 Decision Tree 與 Random Forest 則低於 0.74。在高風險人群的預測能力上，Decision Tree 以平均 0.594 的召回率位居第一，其次是 XGBoost 的 0.555，二者皆高於 Logistic Regression 與 Random Forest；在低風險人群的預測能力上，Logistic Regression 以平均 0.887 的特異度領先其他模型，不過 XGBoost 與 Random Forest 也維持在 0.85 以上，相比之下，Decision Tree 則因為過度追求召回率，使其特異度降為 0.798。另外，各模型的陽性預測值與陰性預測值差異較小，其中 Logistic Regression 的平均陽性預測值最高，而 Decision Tree 與 XGBoost 的陰性預測值分別為 0.808 與 0.805，代表兩個模型具備穩定預測低風險人群的能力。綜上所述，雖然 Decision Tree 的召回率最高，但其特異度表現最差，因此我們最終選擇 XGBoost 作為存活驗證的最佳模型。

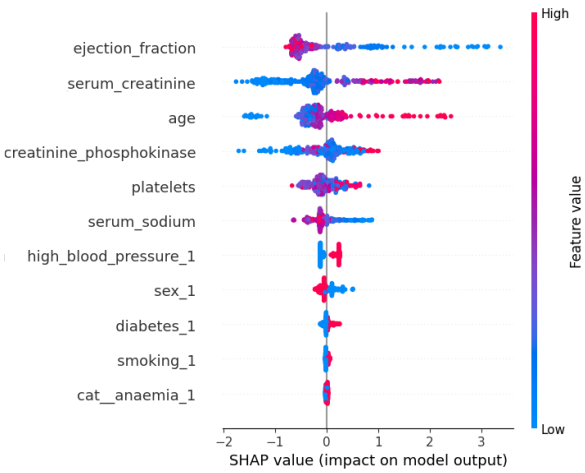


3. 變數解釋與重要性

在 Logistic Regression 模型中，共有四個變數達到統計顯著，分別為年齡、射血分率、CPK 以及血清肌酸酐。在固定其他變數的情況下，年齡每增加一歲，死亡的勝算平均會上升 1.94 倍；射血分率每增加一單位，死亡的勝算則會下降至 0.44 倍；血清肌酸酐每增加一單位，死亡的勝算上升至 1.98 倍；CPK 每增加一單位，死亡的勝算則會上升至 1.32 倍。

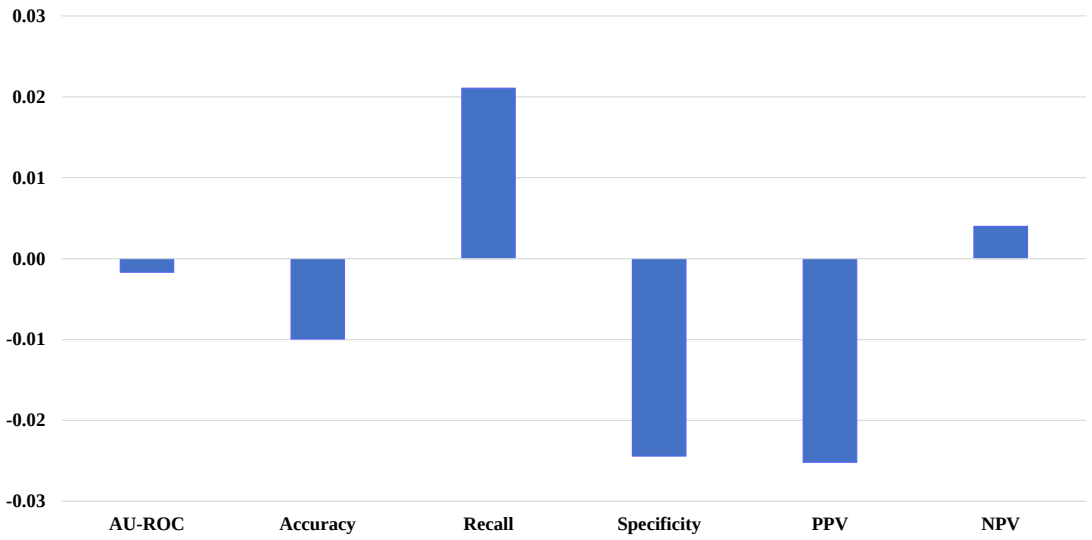
在 XGBoost 模型中，Shapley value 的結果顯示，血清肌酐水準越高、年齡越大、射血分率越低、血清鈉水準越低，死亡的可能性越高。在共病症方面，有高血壓與糖尿病病史者，其死亡風險亦相對較高。由於糖尿病、抽菸狀態及貧血是模型中重要性較低的變數，因此基於模型精簡化的考量，我們排除糖尿病、抽菸狀態及貧血，重新建立一個 Reduced Model，並進一步比較 Full Model 和 Reduced Model 的預測能力。





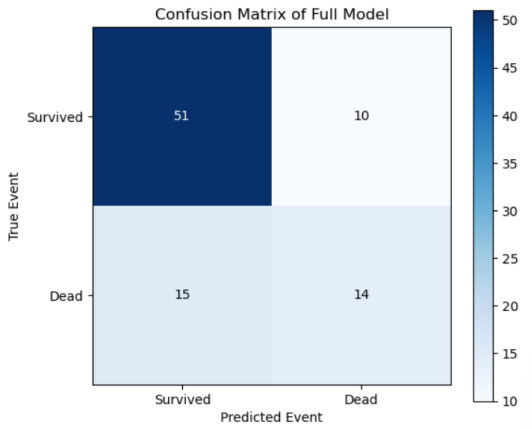
4. 比較 Full Model 和 Reduced Model 的預測結果

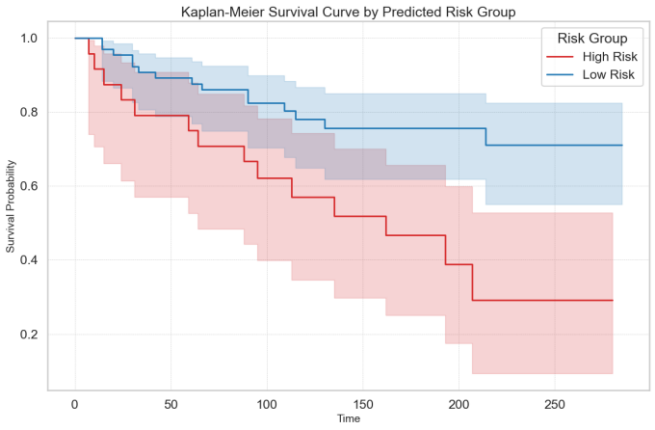
五折交叉驗證下，XGBoost 的 Reduced Model 相較於 Full Model 在各項預測指標的平均表現差異如下圖所示（長條圖代表 Reduced Model 減 Full Model 的值）。結果顯示，Reduced Model 的平均召回率提升了 0.02，代表模型提升識別高風險人群的能力。然而，模型的整體準確率下降 0.01，且特異度也下降了 0.02。其中，陽性預測值的下降幅度最大（0.03）。不過，AU-ROC 在兩個模型間幾乎沒有差異，代表整體預測能力沒有明顯變化。總而言之，Reduced Model 雖提升了對高風險人群的辨識能力，但降低了模型預測高風險人群的正確率和特異度，因此我們認為不應該選擇 Reduced Model 作為最終模型。



5. 驗證模型對存活風險的預測能力

將資料重新切分成 70% 訓練集和 30% 測試集後，我們使用 XGBoost 的最佳參數組合對資料進行預測。混淆矩陣的結果顯示，在 90 位患者中，模型在 61 位實際存活的人群中正確預測出 51 位患者，並錯誤預測 10 位患者會發生死亡事件；模型在 29 位實際死亡的人群中，僅正確預測出 14 位患者，其餘 15 例則被錯誤預測為存活組。計算得出整體準確率、召回率、特異度、陽性預測值及陰性預測值分別為 72.2%、48.3%、83.6%、58.3%及 77.3%，結果顯示模型仍缺乏對高風險患者的識別能力。儘管如此，我們按照模型預測結果將人群分為高風險組和低風險組並進行 Log-rank 檢定，結果顯示 p-value 為 0.0025，拒絕兩組存活情形沒有差異的虛無假設，證明模型預測為高風險的人群在臨床上的存活情形與低風險人群有顯著差異。





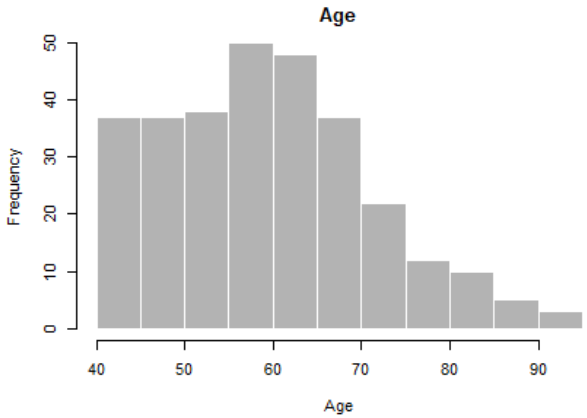
五、 結論與討論

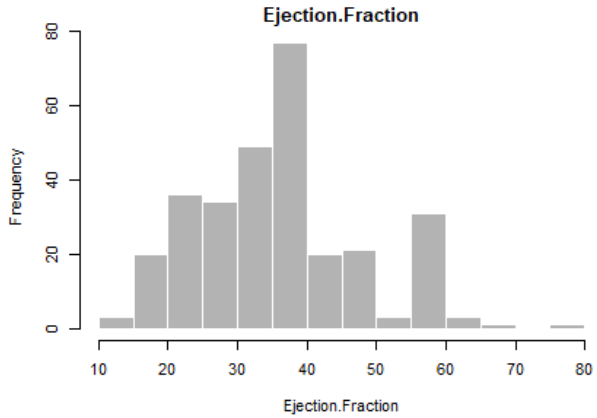
本報告利用臨床數據建立四種具可解釋性的預測模型，輔助醫療決策者提前辨識高風險人群。其中，XGBoost 的預測能力最佳，平均 AU-ROC 達 0.71，但平均召回率僅 0.55。在變數重要性方面，肌酸酐、年齡、射血分率及血清鈉是 XGBoost 模型中關鍵的預測因子。另外，從存活分析的角度來看，XGBoost 模型的分類結果亦能有效區分長期預後較差的高風險人群。儘管如此，我們認為預測模型目前仍無法應用在真實世界中，因為模型錯誤分類高風險人群可能導致醫療決策產生的負面效果，因此仍需進一步改善。

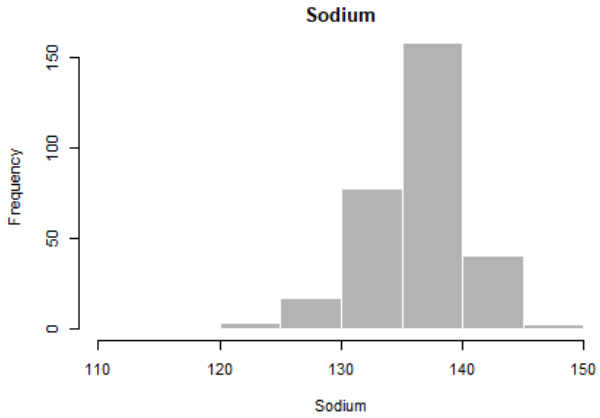
雖然 Random Forest 的 XGBoost 的模型預測能力相近，但考量到 Random Forest 每棵樹的最大深度為 10，相比 XGBoost 每棵樹的最大深度為 3 的設定複雜，因此最終仍以 XGBoost 作為最佳模型選擇。另外，針對 CPK 的異常值，我們有進行敏感度分析。結果發現，刪除 CPK 的異常值後，會使 Decision Tree 和 Random Forest 的各模型評估指標上升，並且導致 XGBoost 和 Logistic Regression 的各模型評估指標下降，然而差異均小於 0.1，故我們認為 CPK 的異常值並不影響本報告的主要結果。

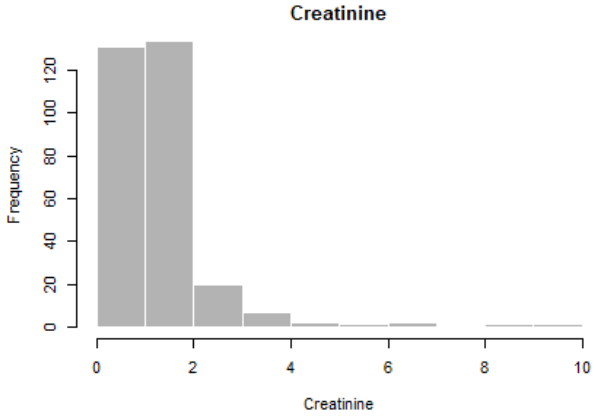
最後，礙於資料的樣本數限制，本次報告僅使用五折交叉驗證，無法有效降低隨機切分資料所產生的隨機誤差。不過，我們透過固定了每一折資料集中死亡組和存活組的比例，盡可能降低隨機誤差。然而，在驗證模型預測為高風險人群的存活情形是否與低風險人群有差異時，我們仍無法避免使用一次性切分資料的方式，因此可能存在較大的隨機誤差。針對這部分，我認為未來可以嘗試兩種方法，第一種方法是尋找外部資料；第二種方法是透過重複抽樣的方式計算每個樣本被歸類為高風險族群的次數，再根據次數多寡決定預測結果，以降低單次切分資料對預測結果產生的影響。

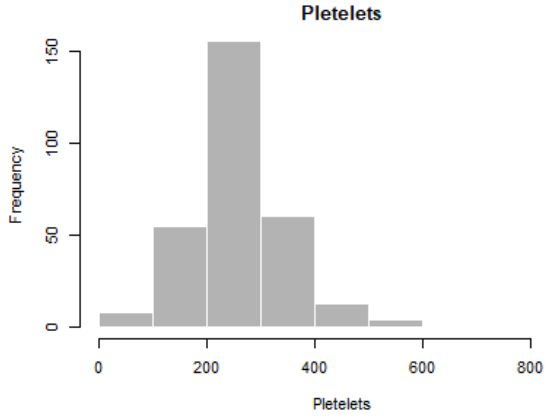
六、 附錄

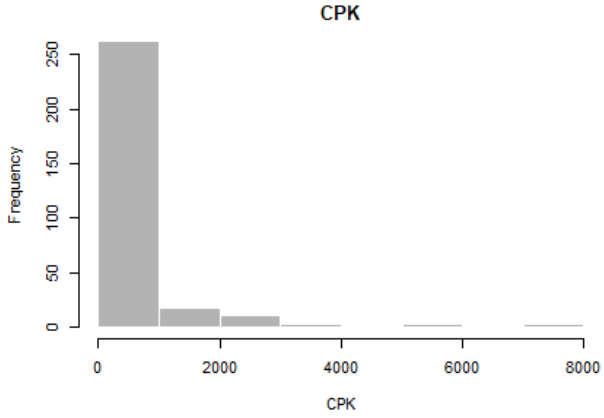

Age
Frequency
0
10
20
30
40
50
40
50
60
70
80
90
Age

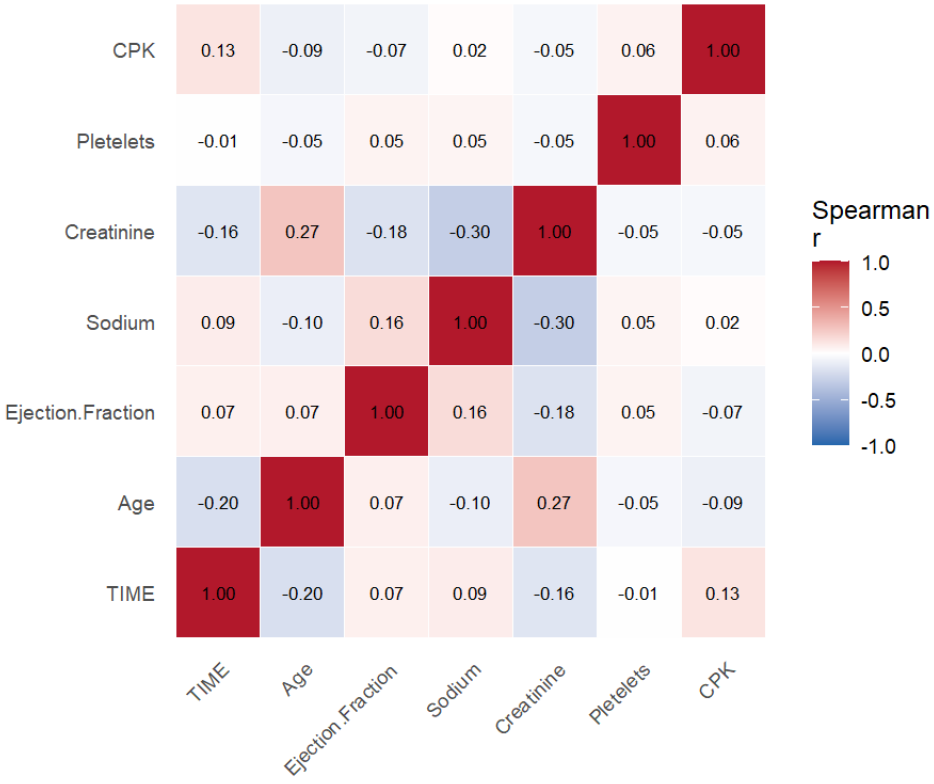

Ejection.Fraction
Frequency
0
20
40
60
80
10
20
30
40
50
60
70
80
Ejection.Fraction

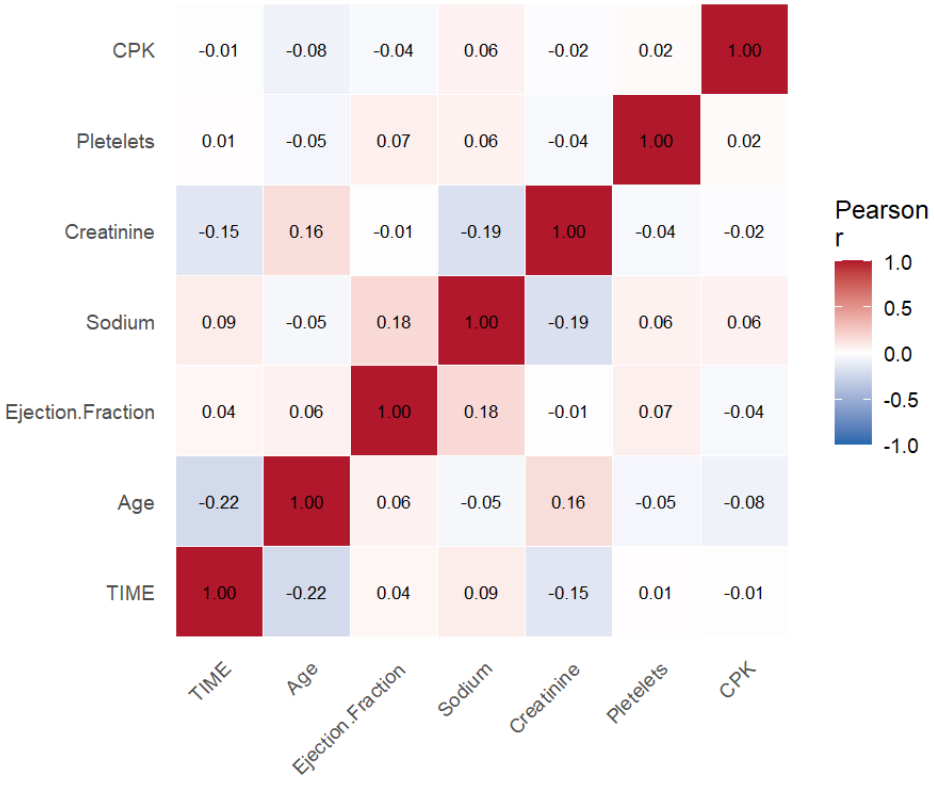

Sodium
Frequency
0
50
100
150
110
120
130
140
150
Sodium


Creatinine
Frequency
0
20
40
60
80
100
120
0
2
4
6
8
10
Creatinine


Pletelets
Frequency
0
50
100
150
0
200
400
600
800
Pletelets

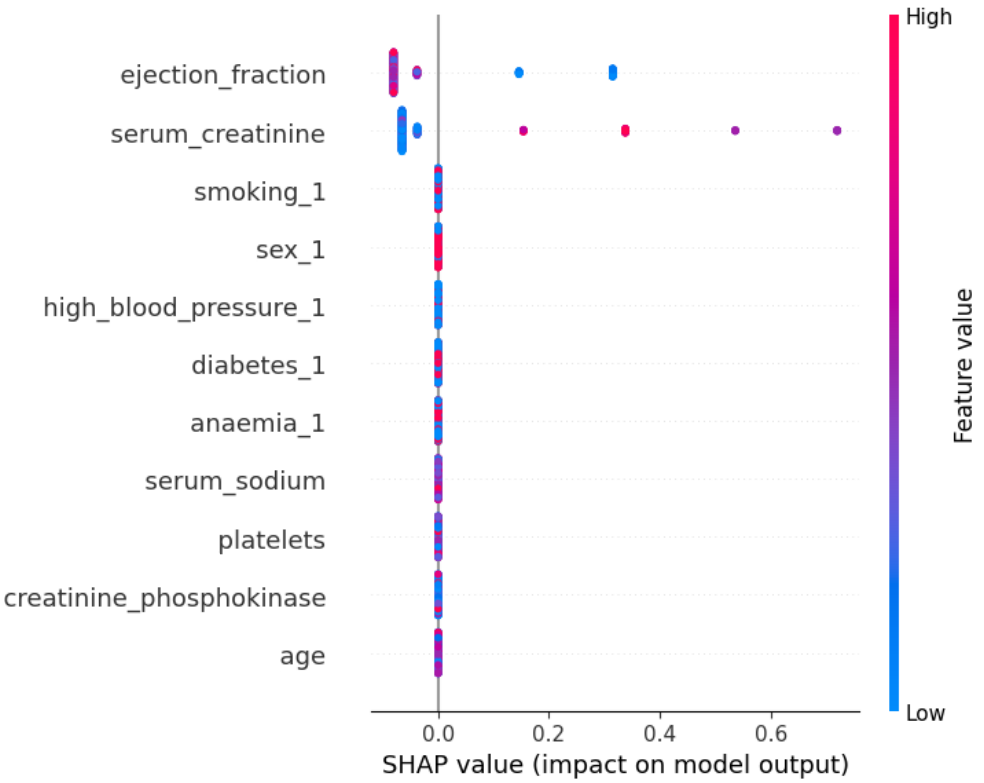

CPK
Frequency
0
50
100
150
200
250
0
2000
4000
6000
8000
CPK


CPK 0.13 -0.09 -0.07 0.02 -0.05 0.06 1.00
Pletelets -0.01 -0.05 0.05 0.05 -0.05 1.00 0.06
Creatinine -0.16 0.27 -0.18 -0.30 1.00 -0.05 -0.05
Sodium 0.09 -0.10 0.16 1.00 -0.30 0.05 0.02
Ejection.Fraction 0.07 0.07 1.00 0.16 -0.18 0.05 -0.07
Age -0.20 1.00 0.07 -0.10 0.27 -0.05 -0.09
TIME 1.00 -0.20 0.07 0.09 -0.16 -0.01 0.13
TIME Age Ejection.Fraction Sodium Creatinine Pletelets CPK
Spearman r
1.0
0.5
0.0
-0.5
-1.0

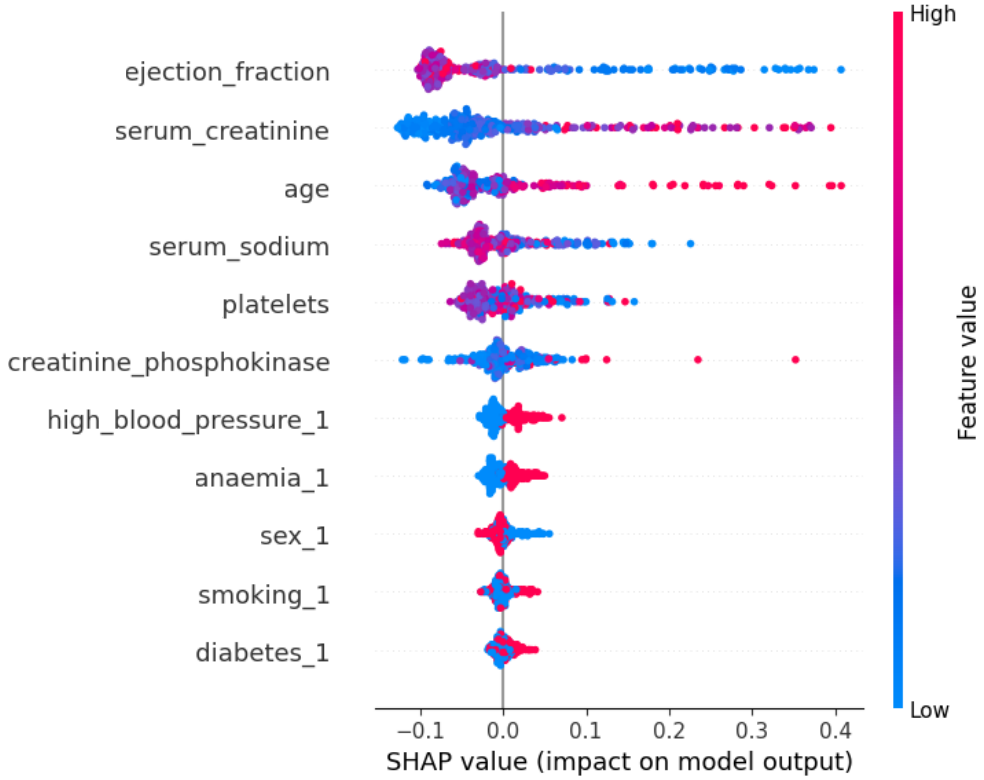

CPK -0.01 -0.08 -0.04 0.06 -0.02 0.02 1.00
Pletelets 0.01 -0.05 0.07 0.06 -0.04 1.00 0.02
Creatinine -0.15 0.16 -0.01 -0.19 1.00 -0.04 -0.02
Sodium 0.09 -0.05 0.18 1.00 -0.19 0.06 0.06
Ejection.Fraction 0.04 0.06 1.00 0.18 -0.01 0.07 -0.04
Age -0.22 1.00 0.06 -0.05 0.16 -0.05 -0.08
TIME 1.00 -0.22 0.04 0.09 -0.15 0.01 -0.01
TIME Age Ejection.Fraction Sodium Creatinine Pletelets CPK
Pearson r
1.0
0.5
0.0
-0.5
-1.0

平均模型預測表現

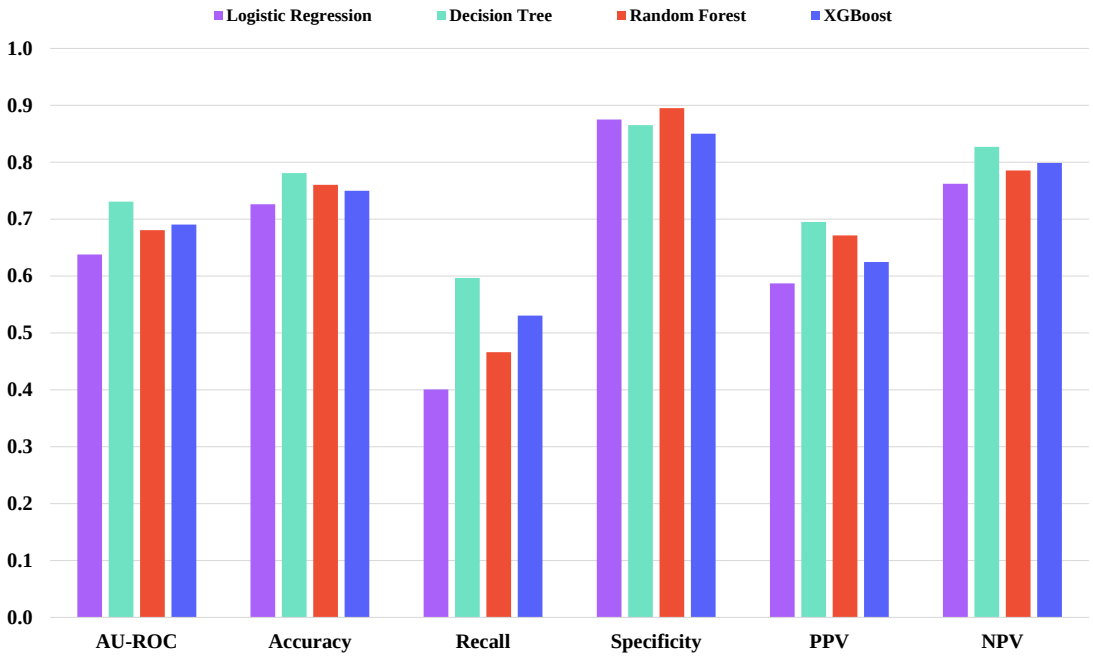
	Logistic Regression	Decision Tree	Random Forest	XGBoost
AU-ROC	0.684	0.696	0.672	0.706
Accuracy	0.756	0.732	0.739	0.759
Recall	0.481	0.594	0.482	0.555
Specificity	0.887	0.798	0.862	0.857
PPV	0.675	0.607	0.625	0.642
NPV	0.783	0.808	0.781	0.805



Decision Tree

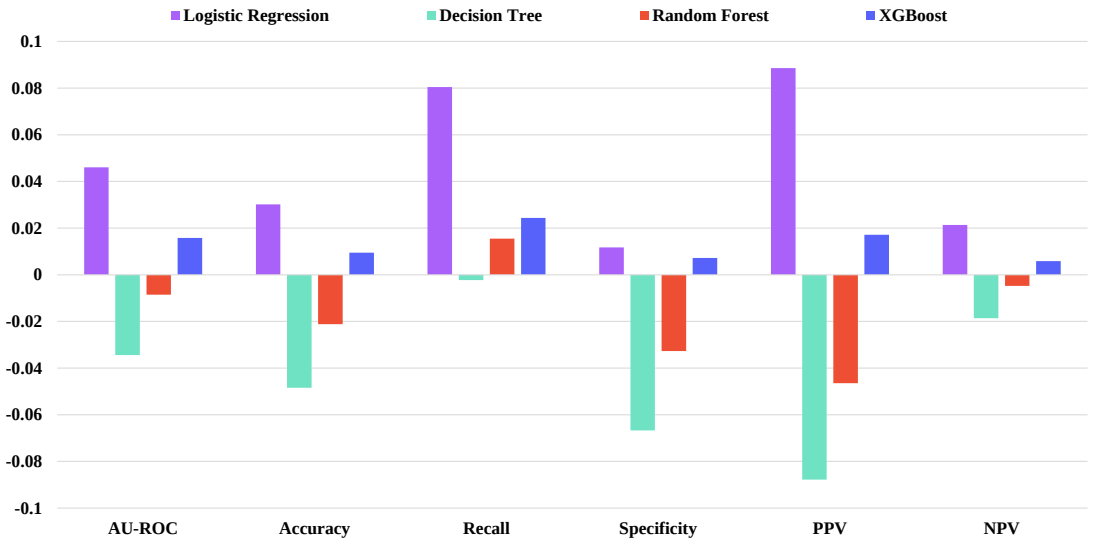


Random Forest



刪除 CPK 異常值的平均模型預測表現

	Logistic Regression	Decision Tree	Random Forest	XGBoost
AU-ROC	0.638	0.731	0.681	0.690
Accuracy	0.726	0.781	0.760	0.750
Recall	0.401	0.597	0.466	0.530
Specificity	0.875	0.865	0.895	0.850
PPV	0.587	0.695	0.671	0.624
NPV	0.762	0.827	0.785	0.799



刪除 CPK 異常值的模型與原始模型表現的差距